

Analyse von RAD-Seq-Daten unter Berücksichtigung von Sequenzierfehlerraten und Heterozygotiewahrscheinlichkeiten

Antonie Vietor

27. Februar 2021

Technische Universität Dortmund Fakultät für Informatik Lehrstuhl 11 Bioinformatics for High-Throughput Technologies http://ls11-www.cs.tu-dortmund.de/

In Kooperation mit: Universität Duisburg-Essen Genome Informatics http://genomeinformatics.uni-due.de/

Aufbau von DNA und RNA

Aufbau der DNA

- besteht aus Nukleotiden
- jedes Nukleotid besteht aus einem Zuckermolekül (Desoxyribose), einem Phosphatrest und einer Base
- Basen: A (Adenin), T (Thymin), G (Guanin), C (Cytosin)
- meist doppelsträngig
- dient vor allem der Informationsspeicherung (Erbinformation)

Aufbau von DNA und RNA

Aufbau der DNA

- besteht aus Nukleotiden
- jedes Nukleotid besteht aus einem Zuckermolekül (Desoxyribose), einem Phosphatrest und einer Base
- Basen: A (Adenin), T (Thymin), G (Guanin), C (Cytosin)
- meist doppelsträngig
- dient vor allem der Informationsspeicherung (Erbinformation)

Unterschiede im Aufbau der RNA

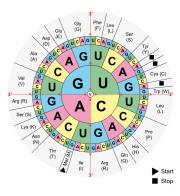
- Nukleotide: das Zuckermolekül ist Ribose
- Basen: Uracil (U) statt Thymin
- meist einzelsträngig
- viele Funktionen, dient unter anderem der Informationsübertragung bei der Proteinbiosynthese

Struktur der DNA

- Doppelhelixstruktur
- Komplementarität: selektive Basenpaarung von A und T und ebenso von G und C
- Antiparallelität: in der Doppelhelix sind die beiden DNA-Stränge gegenläufig zu einander
- Gene: Wechsel von codierenden (Exons) und nicht-codierenden Abschnitten (Introns)
- zwischen den Genen nicht-codierende Bereiche, z.T. mit regulatorischen Funktionen
- ca. 98 % der DNA sind nicht-codierend

Genetischer Code

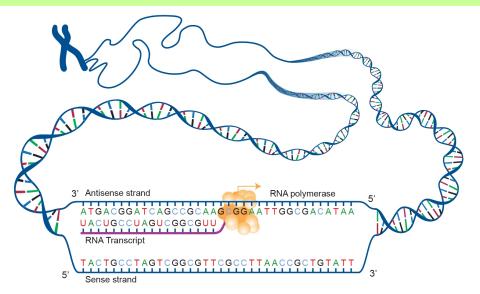
- Codierung der DNA-Sequenz in eine Aminosäuresequenz, welche die Primärstruktur der Proteine darstellt
- Basentripletts (Codons) codieren für i.d.R. 20 Aminosäuren sowie ein Startund drei Stop-Codons
- Degeneration: mehrere Basentripletts können für die gleiche Aminosäure codieren



Bildauelle: [1]

Transkription

Umschreiben eines DNA-Abschnitts zu Arbeitskopien in Form von **mRNA** (messenger RNA)



Bildquelle: [2]

Translation

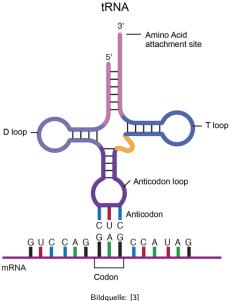
• Übersetzen der Basensequenz in die Aminosäuresequenz mit Hilfe von tRNA (transfer RNA)

Translation

- Übersetzen der Basensequenz in die Aminosäuresequenz mit Hilfe von tRNA (transfer RNA)
- Aufbau der tRNA:
 - ⇒ mRNA-Bindungsstelle bestehend aus einem Basentriplett

Translation

- Übersetzen der Basensequenz in die Aminosäuresequenz mit Hilfe von tRNA (transfer RNA)
- Aufbau der tRNA:
 - ⇒ mRNA-Bindungsstelle bestehend aus einem Basentriplett
 - ⇒ trägt die **korrespondierende Aminosäure** (AS), die nach dem genetischen Code der mRNA-Bindungsstelle entspricht

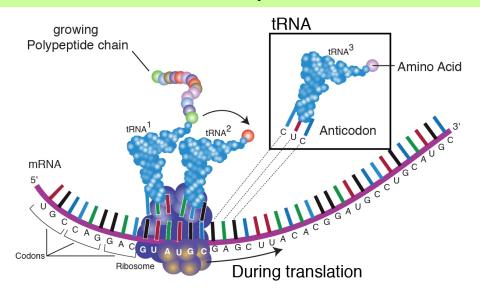


Translation

- Übersetzen der Basensequenz in die Aminosäuresequenz mit Hilfe von tRNA (transfer RNA)
- Aufbau der tRNA:
 - ⇒ mRNA-Bindungsstelle bestehend aus einem Basentriplett
 - ⇒ trägt die **korrespondierende Aminosäure** (AS), die nach dem genetischen Code der mRNA-Bindungsstelle entspricht

Translation

- Übersetzen der Basensequenz in die Aminosäuresequenz mit Hilfe von tRNA (transfer RNA)
- Aufbau der tRNA:
 - ⇒ mRNA-Bindungsstelle bestehend aus einem Basentriplett
 - ⇒ trägt die **korrespondierende Aminosäure** (AS), die nach dem genetischen Code der mRNA-Bindungsstelle entspricht
- von der Startsequenz ausgehend werden die tRNAs mit komplementärer Bindungsstelle nacheinander an die mRNA gebunden, dadurch wird ihre AS gelöst und an die AS der nachfolgenden tRNA gebunden ⇒ es entsteht eine Aminosäuresequenz



Bildquelle: [4]

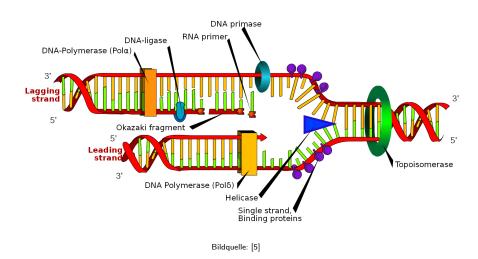
Natürlicher Vorgang zur Vervielfältigung der DNA bei der Zellteilung:

• Entwindung der DNA (**Topoisomerasen**)

- Entwindung der DNA (**Topoisomerasen**)
- Auftrennung des DNA-Doppelstrangs (Helikase)

- Entwindung der DNA (**Topoisomerasen**)
- 4 Auftrennung des DNA-Doppelstrangs (Helikase)
- Synthese der RNA-Primer (Primasen)

- Entwindung der DNA (**Topoisomerasen**)
- Auftrennung des DNA-Doppelstrangs (Helikase)
- Synthese der RNA-Primer (Primasen)
- Kopieren der beiden Elternstränge ausgehend von den RNA-Primern (DNA-Polymerasen)



6 / 60

- Entwindung der DNA (**Topoisomerasen**)
- Auftrennung des DNA-Doppelstrangs (Helikase)
- Synthese der RNA-Primer (Primasen)
- Kopieren der beiden Elternstränge ausgehend von den RNA-Primern (DNA-Polymerasen)

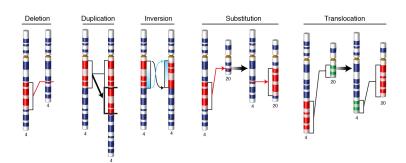
- Entwindung der DNA (**Topoisomerasen**)
- 4 Auftrennung des DNA-Doppelstrangs (Helikase)
- Synthese der RNA-Primer (Primasen)
- Kopieren der beiden Elternstränge ausgehend von den RNA-Primern (DNA-Polymerasen)
 - ⇒ es entstehen zwei komplementäre Tochterstränge

- Entwindung der DNA (**Topoisomerasen**)
- 4 Auftrennung des DNA-Doppelstrangs (Helikase)
- Synthese der RNA-Primer (Primasen)
- Kopieren der beiden Elternstränge ausgehend von den RNA-Primern (DNA-Polymerasen)
 - ⇒ es entstehen zwei komplementäre Tochterstränge
 - ⇒ kontinuierliche Synthese des Leitstrangs

- Entwindung der DNA (**Topoisomerasen**)
- Auftrennung des DNA-Doppelstrangs (Helikase)
- Synthese der RNA-Primer (Primasen)
- Kopieren der beiden Elternstränge ausgehend von den RNA-Primern (DNA-Polymerasen)
 - ⇒ es entstehen zwei komplementäre Tochterstränge
 - ⇒ kontinuierliche Synthese des Leitstrangs
 - ⇒ diskontinuierliche Synthese des Folgestrangs (Okazaki-Fragmente)

- Entwindung der DNA (**Topoisomerasen**)
- Auftrennung des DNA-Doppelstrangs (Helikase)
- Synthese der RNA-Primer (Primasen)
- Kopieren der beiden Elternstränge ausgehend von den RNA-Primern (DNA-Polymerasen)
 - ⇒ es entstehen zwei komplementäre Tochterstränge
 - ⇒ kontinuierliche Synthese des Leitstrangs
 - ⇒ diskontinuierliche Synthese des Folgestrangs (Okazaki-Fragmente)
- Verbindung der Okazaki-Fragmente des Folgestrangs (Ligase)

Mutationen



Bildquelle: [6]

Mutationen



Deletion

...GTCGAGTCTA CGCTATCGCT... ...CAGCTCAGAT GGCTATCGCT...

Insertion

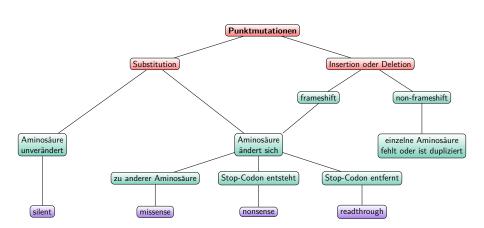


Bildquelle: [6]

Substitution



Mutationen



Folgen von Mutationen

- Loss-of-function-Mutationen
- Gain-of-function-Mutationen

Folgen von Mutationen

- Loss-of-function-Mutationen
- Gain-of-function-Mutationen

Varianten

- oft Varianten einzelner Basen: SNPs (single nucleotide polymorphism)
- ohne pathologische Auswirkungen
- vermehrtes Auftreten innerhalb einer Spezies

Folgen von Mutationen

- Loss-of-function-Mutationen
- Gain-of-function-Mutationen

Varianten

- oft Varianten einzelner Basen: SNPs (single nucleotide polymorphism)
- ohne pathologische Auswirkungen
- vermehrtes Auftreten innerhalb einer Spezies

Allele, Locus, Ploidie und Genotyp

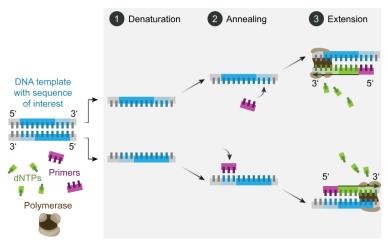
- Allele: verschiedene Varianten eines genomischen Ortes (Locus)
- Ploidie: Anzahl der Chromosomensätze (homologe Chromosomen)
- Genotyp:
 - ⇒ **Homozygotie**: an einem Locus liegt auf allen homologen Chromosomen das gleiche Allel vor
 - ⇒ **Heterozygotie**: die homologen Chromosomen weisen an einem Locus unterschiedliche Allele auf

- Methode zur Vervielfältigung von DNA-Abschnitten
- mehrere Zyklen der folgenden temperaturabhängigen Schritte:

- Methode zur Vervielfältigung von DNA-Abschnitten
- mehrere Zyklen der folgenden temperaturabhängigen Schritte:
 - Denaturierung: durch Erhitzen wird der DNA-Doppelstrang in zwei Einzelstränge aufgespalten (96°C)

- Methode zur Vervielfältigung von DNA-Abschnitten
- mehrere Zyklen der folgenden temperaturabhängigen Schritte:
 - **Denaturierung**: durch Erhitzen wird der DNA-Doppelstrang in zwei Einzelstränge aufgespalten (96°C)
 - **Annealing**: Primerbindung an den 3'-Enden der zu amplifizierenden Gensequenz beider Einzelstränge (55-65°C)

- Methode zur Vervielfältigung von DNA-Abschnitten
- mehrere Zyklen der folgenden temperaturabhängigen Schritte:
 - **Denaturierung**: durch Erhitzen wird der DNA-Doppelstrang in zwei Einzelstränge aufgespalten (96°C)
 - Annealing: Primerbindung an den 3'-Enden der zu amplifizierenden Gensequenz beider Einzelstränge (55-65°C)
 - 3 Elongation: DNA-Synthese der komplementären Stränge (72°C)

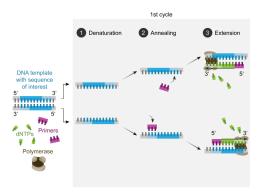


Bildquelle: [7]

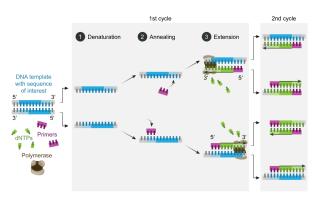
9 / 60

- Methode zur Vervielfältigung von DNA-Abschnitten
- mehrere Zyklen der folgenden temperaturabhängigen Schritte:
 - **Denaturierung**: durch Erhitzen wird der DNA-Doppelstrang in zwei Einzelstränge aufgespalten (96°C)
 - Annealing: Primerbindung an den 3'-Enden der zu amplifizierenden Gensequenz beider Einzelstränge (55-65°C)
 - **Selongation**: DNA-Synthese der komplementären Stränge (72°C)

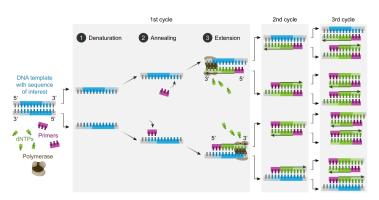
- Methode zur Vervielfältigung von DNA-Abschnitten
- mehrere Zyklen der folgenden temperaturabhängigen Schritte:
 - **Denaturierung**: durch Erhitzen wird der DNA-Doppelstrang in zwei Einzelstränge aufgespalten (96°C)
 - Annealing: Primerbindung an den 3'-Enden der zu amplifizierenden Gensequenz beider Einzelstränge (55-65°C)
 - Elongation: DNA-Synthese der komplementären Stränge (72°C)
- mit jedem Zyklus wird die betreffende Sequenz verdoppelt
- in Abhängigkeit von der Anzahl der durchgeführten Zyklen n exponentieller Anstieg der Kopien 2ⁿ



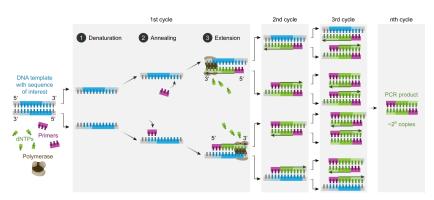
Bildquelle: [7]



Bildquelle: [7]



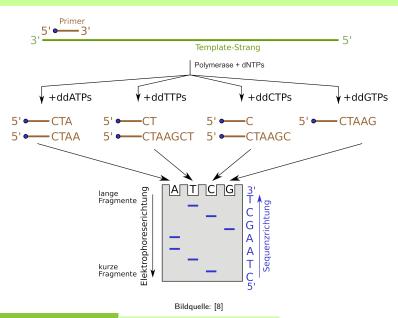
Bildquelle: [7]



Bildquelle: [7]

Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird



Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird

Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird

NGS-Sequenzierung

verbesserte Sequenziertechnologien im Hochdurchsatzverfahren

Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird

NGS-Sequenzierung

verbesserte Sequenziertechnologien im Hochdurchsatzverfahren

RAD-Sequenzierung

restriction site associated DNA sequencing

Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird

NGS-Sequenzierung

verbesserte Sequenziertechnologien im Hochdurchsatzverfahren

RAD-Sequenzierung

- restriction site associated DNA sequencing
- Anwendung: Populationsgenetik, Ökologie, Genotypisierung, Evolutionsforschung

Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird

NGS-Sequenzierung

verbesserte Sequenziertechnologien im Hochdurchsatzverfahren

RAD-Sequenzierung

- restriction site associated DNA sequencing
- Anwendung: Populationsgenetik, Ökologie, Genotypisierung, Evolutionsforschung
- Sequenzierung multipler kleiner DNA-Fragmente aus dem gesamten Genom

Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird

NGS-Sequenzierung

verbesserte Sequenziertechnologien im Hochdurchsatzverfahren

RAD-Sequenzierung

- restriction site associated DNA sequencing
- Anwendung: Populationsgenetik, Ökologie, Genotypisierung, Evolutionsforschung
- Sequenzierung multipler kleiner DNA-Fragmente aus dem gesamten Genom
- gleichzeitige Analyse mehrerer Individuen in gepoolten Proben

Sanger-Sequenzierung

Kettenabbruch-Synthese mit vier Probenansätzen denen jeweils eine der vier möglichen Nukleotide in modifizierter Form beigefügt wird

NGS-Sequenzierung

verbesserte Sequenziertechnologien im Hochdurchsatzverfahren

RAD-Sequenzierung

- restriction site associated DNA sequencing
- Anwendung: Populationsgenetik, Ökologie, Genotypisierung, Evolutionsforschung
- Sequenzierung multipler kleiner DNA-Fragmente aus dem gesamten Genom

Sequenzierung

- gleichzeitige Analyse mehrerer Individuen in gepoolten Proben
- benötigt kein Referenzgenom

Restriktionsenzyme

 molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden

11 / 60

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

11 / 60

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

CCCGGG GGGCCC

Bildquelle: [8]

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein



Bildquelle: [8]

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

Methode

DNA-Verdau durch Restriktionsenzyme

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

Methode

- ONA-Verdau durch Restriktionsenzyme
- Sequenz der Restriktionsstelle ist bekannt, dies ermöglicht die Bindung der Adapter- und Barcodesequenzen

11 / 60

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

Methode

- ONA-Verdau durch Restriktionsenzyme
- Sequenz der Restriktionsstelle ist bekannt, dies ermöglicht die Bindung der Adapter- und Barcodesequenzen
- Größenselektion der DNA-Fragmente

11 / 60

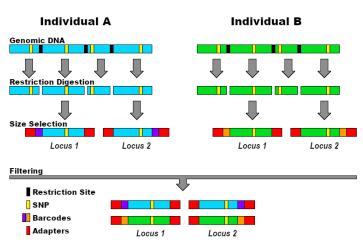
Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

Methode

- DNA-Verdau durch Restriktionsenzyme
- Sequenz der Restriktionsstelle ist bekannt, dies ermöglicht die Bindung der Adapter- und Barcodesequenzen
- Größenselektion der DNA-Fragmente
- Sequenzierung der gepoolten Proben verschiedener Individuen

Restriction-site Associate DNA Sequencing (RADSeq)



Bildquelle: [9] (modifiziert)

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

Methode

- ONA-Verdau durch Restriktionsenzyme
- Sequenz der Restriktionsstelle ist bekannt, dies ermöglicht die Bindung der Adapter- und Barcodesequenzen
- Größenselektion der DNA-Fragmente
- Sequenzierung der gepoolten Proben verschiedener Individuen

ddRADSeq (double digest RAD sequencing)

Verwendung von zwei verschiedenen Restriktionsenzymen

Restriktionsenzyme

- molekulare Scheren, welche die DNA an spezifischen Sequenzen schneiden
- Enden können glatt oder versetzt sein

Methode

- ONA-Verdau durch Restriktionsenzyme
- Sequenz der Restriktionsstelle ist bekannt, dies ermöglicht die Bindung der Adapter- und Barcodesequenzen
- Größenselektion der DNA-Fragmente
- Sequenzierung der gepoolten Proben verschiedener Individuen

ddRADSeq (double digest RAD sequencing)

- Verwendung von zwei verschiedenen Restriktionsenzymen
- bessere Steuerbarkeit und höhere Genauigkeit

 durch die Sequenzspezifität der Restriktionsenzyme stammen die DNA-Fragmente bei den verschiedenen Individuen meistens vom gleichen genomischen Locus

- durch die Sequenzspezifität der Restriktionsenzyme stammen die DNA-Fragmente bei den verschiedenen Individuen meistens vom gleichen genomischen Locus
- interindividueller Vergleich ist ohne Referenzgenom möglich

- durch die Sequenzspezifität der Restriktionsenzyme stammen die DNA-Fragmente bei den verschiedenen Individuen meistens vom gleichen genomischen Locus
- interindividueller Vergleich ist ohne Referenzgenom möglich
- **gepoolte Proben**: Zeit- und Kostenersparnis, gleiche Versuchsbedingungen für die verschiedenen Individuen

- durch die Sequenzspezifität der Restriktionsenzyme stammen die DNA-Fragmente bei den verschiedenen Individuen meistens vom gleichen genomischen Locus
- interindividueller Vergleich ist ohne Referenzgenom möglich
- **gepoolte Proben**: Zeit- und Kostenersparnis, gleiche Versuchsbedingungen für die verschiedenen Individuen
- die DNA-Fragmente stammen aus dem gesamten Genom, aber keine vollständige genomische Abdeckung

Problemstellung

Problem:

- Reads ohne Kenntnis eines Referenzgenoms möglichen Loci zuordnen
- die Loci und ihre Sequenz sind unbekannt

Problemstellung

Problem:

- Reads ohne Kenntnis eines Referenzgenoms möglichen Loci zuordnen
- die Loci und ihre Sequenz sind unbekannt

Gegeben:

- Menge von Reads: $D = (s_1, \ldots, s_m) \in \{A, C, G, T,\}^{k^m}$
- Qualität der Sequenzierung: $Q = (q_1, \ldots, q_m) \in [0, 1]^{k^m}$
- Sequenzierfehlerraten: $\epsilon = \{\epsilon_{\textit{ins}}, \, \epsilon_{\textit{del}}\}$
- Heterozygotiewahrscheinlichkeiten: $\eta = \{\eta_{sub}, \, \eta_{ins}, \, \eta_{del}\}$
- Ploidie: ϕ

Problemstellung

Problem:

- Reads ohne Kenntnis eines Referenzgenoms möglichen Loci zuordnen
- die Loci und ihre Sequenz sind unbekannt

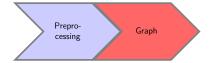
Gegeben:

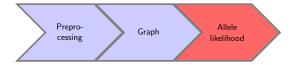
- Menge von Reads: $D = (s_1, \ldots, s_m) \in \{A, C, G, T,\}^{k^m}$
- Qualität der Sequenzierung: $Q = (q_1, \ldots, q_m) \in [0, 1]^{k^m}$
- Sequenzierfehlerraten: $\epsilon = \{\epsilon_{\textit{ins}}, \, \epsilon_{\textit{del}}\}$
- Heterozygotiewahrscheinlichkeiten: $\eta = \{\eta_{sub}, \, \eta_{ins}, \, \eta_{del}\}$
- Ploidie: ϕ

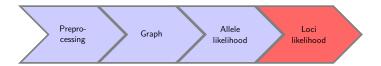
Ziel:

- ullet Zuordnung der Reads zu den Loci unter Berücksichtigung von ϵ und η
- Ausgabe der Menge der ermittelten Loci mit den Sequenzen der beteiligten Allele
- ⇒ die Loci können anschließend für Diversitätsanalysen genutzt werden





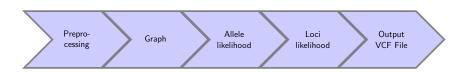




Model

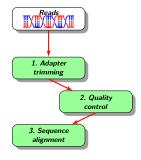


Model

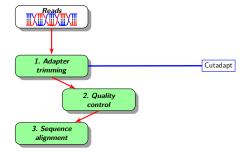




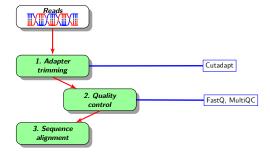




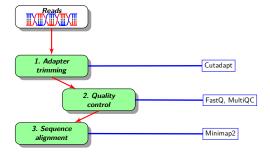








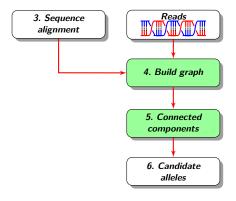




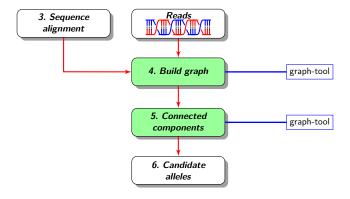








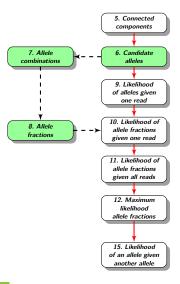




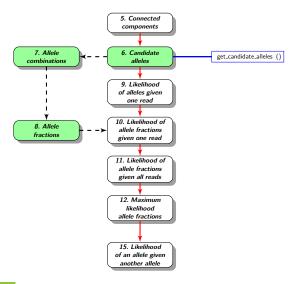




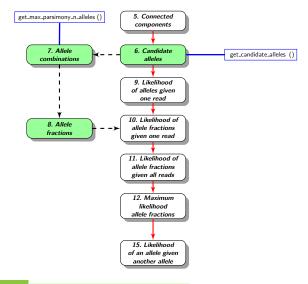




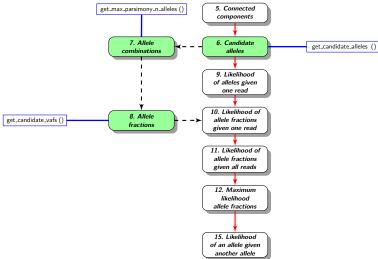






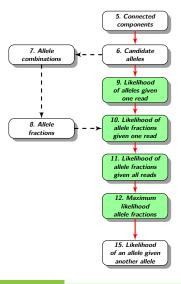




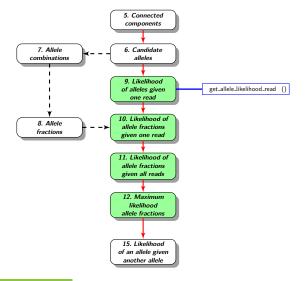




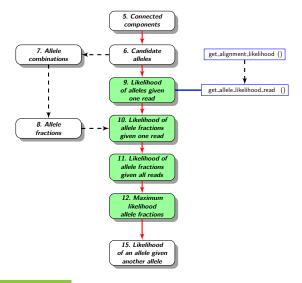




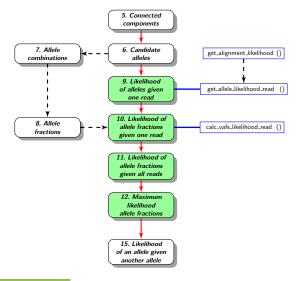




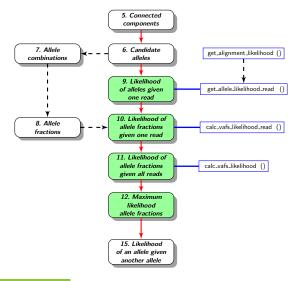








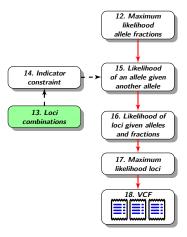




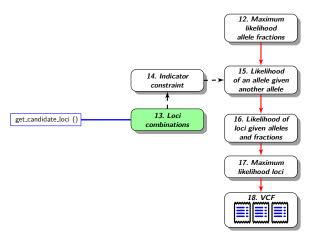






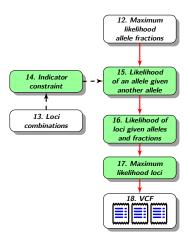


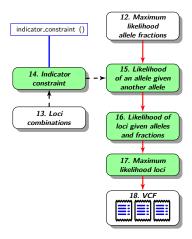


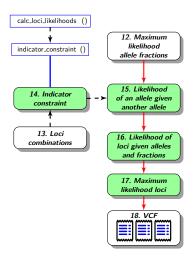




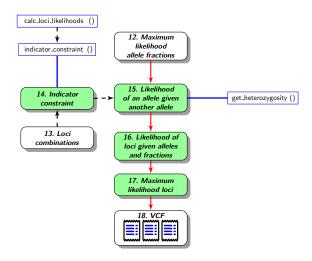




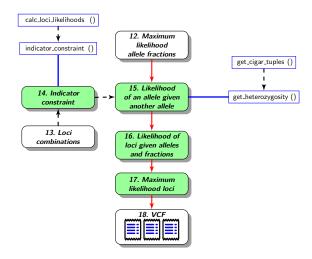




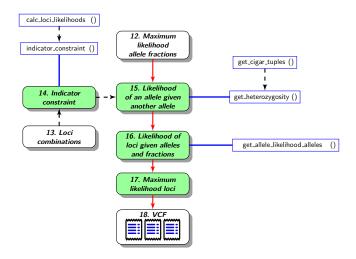








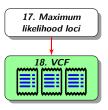




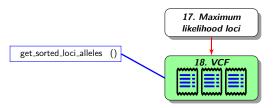




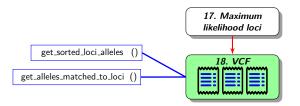




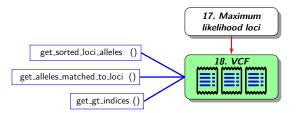




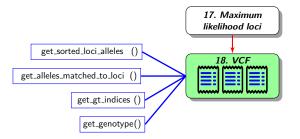












Bildquellen I

- [1] MOUAGIP: Aminoacids table.svg. 2021. source: https: //commons.wikimedia.org/wiki/File:Aminoacids_table.svg
- [2] MARGULIES, Elliott: *Transcription*. source: https://www.genome.gov/genetics-glossary/Transcription
- [3] LEJA, Darryl: Transfer RNA (tRNA). source: https://medlineplus.gov/genetics/understanding/basics/ noncodingdna/
- [4] MARGULIES, Elliott: Transfer RNA (tRNA). source: https://www.genome.gov/genetics-glossary/Transfer-RNA
- [5] Ruiz, Mariana: DNA replication. source: https://commons.wikimedia.org/wiki/File: DNA_replication_en.svg
- [6] COLLINS, Francis: *Mutation*. source: https://www.genome.gov/genetics-glossary/Mutation

Bildquellen II

- [7] ENZOKLOP: Polymerase Chain Reaction Schematic mechanism of PCR. source: https://en.wikipedia.org/wiki/File: Polymerase_chain_reaction-en.svg
- [8] Christoph Goemans, Norman M.: Prinzip der DNA-Sequenzierung nach der Didesoxy-Methode. source: https://de.wikipedia.org/wiki/Datei:Didesoxy-Methode.svg
- [9] CLARK, Jonathan: Schematic diagram of RADseq. source: https://en.wikipedia.org/wiki/File:RADseq_schematic.pdf
- [10] ALANIS, Cristo J.: Schema of Labs on a class. source: https://texample.net/tikz/examples/labs-schema/
- [11] VELICKOVIC, Petar: Deoxyribonucleic acid (DNA). source: https://github.com/PetarV-/TikZ/tree/master/DNA
- [12] TWITTER, Inc.; OTTO, Mark; BOOTSTRAP AUTHORS the:
 Bootstrap icons receipt. source: https:
 //github.com/twbs/icons/blob/main/icons/receipt.svg